

Inferencia Bayesiana

Alumno:

Huertas Quispe, Anthony Enrique

Cod: 20173728

Semestre: 2018-I

Tema: PC 2

PROF. VICTOR GIANCARLO SAL Y ROSAS



Pontificia Universidad Católica del Perú
Escuela de Posgrado
Maestría en Estadística

Problema 1. Solución

Tenemos:

$$f(x, y) \propto \exp(-[\lambda x + \lambda y + \mu xy]), \quad x \geq 0, \quad y \geq 0 \quad (1)$$

a) Determinando distribuciones condicionales

$$\begin{aligned} f(x|Y=y) &\propto \exp(-[\lambda x + \lambda y + \mu xy]) \\ &\propto \exp(-[\lambda x + \mu xy]) \\ &\propto \exp(-x[\lambda + \mu y]) \\ \Rightarrow X|Y=y &\sim \text{Exp}(\lambda + \mu y) \end{aligned} \quad (2)$$

Análogamente obtenemos la distribución de $Y|X=x$

$$\begin{aligned} f(y|X=x) &\propto \exp(-[\lambda x + \lambda y + \mu xy]) \\ &\propto \exp(-[\lambda y + \mu xy]) \\ &\propto \exp(-y[\lambda + \mu x]) \\ \Rightarrow Y|X=x &\sim \text{Exp}(\lambda + \mu x) \end{aligned} \quad (3)$$

Listing 1: Algoritmo Gibbs Preg 1

```

1 ##### PREGUNTA 1
2
3 I      <- 10000
4 PARA   <- matrix(0,nrow=I,2)
5 # Dos columnas: Primera x, segunda y
6
7 PARA[1,] <- c(5,5)
8 lambda <- 1
9 mu <- 1
10 cont=numeric(I)
11
12 for(i in 2:I){
13     #
14     # x
15     #
16     PARA[i,1] <- rexp(1,lambda+mu*PARA[i-1,2])
17     #
18     # y
19     #
20     PARA[i,2] <- rexp(1,lambda + mu*PARA[i,1])
21     if(PARA[i,1]< 1 & PARA[i,2] < 1 ){cont[i]=1 }
22 }
23
24 x = PARA[1000:I,1]
25 y = PARA[1000:I,2]
26 hist(x)
27 hist(y)
28
29 #1.b
30 sim <- cbind(x,y)
31 colnames(sim)[1:2] <- c("x","y")

```

```

32 sim      <- as.mcmc(sim)
33 summary(sim)
34
35 #CONCLUSION:— La media de X es 0.68 aproximadamente
36 #           — La desviacion estandar de X es 0.7484
37
38
39 #1.c
40 p = sum(cont[1000:I])/(I-999)
41 p
42
43 #CONCLUSION:— La probabilidad de que X e Y sean menores que 1 es de
44 # aproximadamente 0.57
45 }

```

Pregunta 6. Solución

Se tiene una distribución para la v.a. Y como:

$$Y \sim t(\mu, \sigma^2, v) \quad (4)$$

donde $\mu > 0$, $\sigma^2 > 0$ y $v > 0$.

Además,

$$Y|W \sim N(\mu, \sigma^2) \quad (5)$$

$$W \sim \text{Gamma}\left(\frac{v}{2}, \frac{v}{2}\right) \quad (6)$$

Tenemos Y_1, \dots, Y_n condicionales a $\beta = (\beta_0, \beta_1)^T$ y τ tales que

$$Y_i|\beta, \tau \sim t(x_i^T \beta, \frac{1}{\tau}, 3) \quad (7)$$

y

$$p(\beta, \tau) \propto \frac{1}{\tau} \quad (8)$$

a) Distribución a posteriori aumentada de $\theta = (\beta, \tau)$ y W .

$$\begin{aligned}
 p(\beta, \tau, W | \text{Datos}) &\propto \prod_{i=1}^n p(y_i | \beta, \tau, w_i) p(w_i | \beta, \tau) \times \frac{1}{\tau} \\
 &\propto \prod_{i=1}^n (\tau w_i)^{1/2} \exp \left\{ -\frac{\tau w_i}{2} (y_i - x_i^T \beta)^2 \right\} \quad (9)
 \end{aligned}$$

$$\begin{aligned}
 &\times \prod_{i=1}^n w_i^{3/2-1} \exp \left\{ -\frac{3}{2} w_i \right\} \times \frac{1}{\tau} \quad (10)
 \end{aligned}$$

b) Distribuciones condicionales:

$$\begin{aligned}
 p(w_i|\beta, \tau, \text{Datos}) &\propto w_i^{1/2} \exp \left\{ -w_i \left(\frac{3}{2} + \frac{\tau}{2} (y_i - x_i^T \beta)^2 \right) w_i^{1/2} \right\} \\
 &\propto w_i \exp \left\{ -w_i \left(\frac{3}{2} + \frac{\tau}{2} (y_i - x_i^T \beta)^2 \right) \right\} \\
 &\Rightarrow w_i \sim \text{Gamma} \left(2, \frac{3}{2} + \frac{\tau}{2} (y_i - x_i^T \beta)^2 \right)
 \end{aligned} \tag{11}$$

$$\begin{aligned}
 p(\beta|\tau, W, \text{Datos}) &\propto \exp \left\{ -\frac{\tau}{2} [\beta^T X W X^T \beta - 2\beta^T X W Y] \right\} \\
 &\Rightarrow \beta|\tau, W, \text{Datos} \sim N_2 \left((X W X^T)^{-1} X W Y, \frac{(X W X^T)^{-1}}{\tau} \right)
 \end{aligned} \tag{12}$$

$$\begin{aligned}
 p(\tau|\beta, W, \text{Datos}) &\propto \tau^{n/2} \exp \left\{ -\frac{\tau}{2} \sum_{i=1}^n w_i (y_i - x_i^T \beta)^2 \right\} \frac{1}{\tau} \\
 &\propto \tau^{n/2-1} \exp \left\{ -\frac{\tau}{2} \sum_{i=1}^n w_i (y_i - x_i^T \beta)^2 \right\} \\
 &\Rightarrow \tau|\beta, W, \text{Datos} \sim \text{Gamma} \left(\frac{n}{2}, \frac{1}{2} \sum_{i=1}^n w_i (y_i - x_i^T \beta)^2 \right)
 \end{aligned} \tag{13}$$

Listing 2: Algoritmo Gibbs Preg 6

```

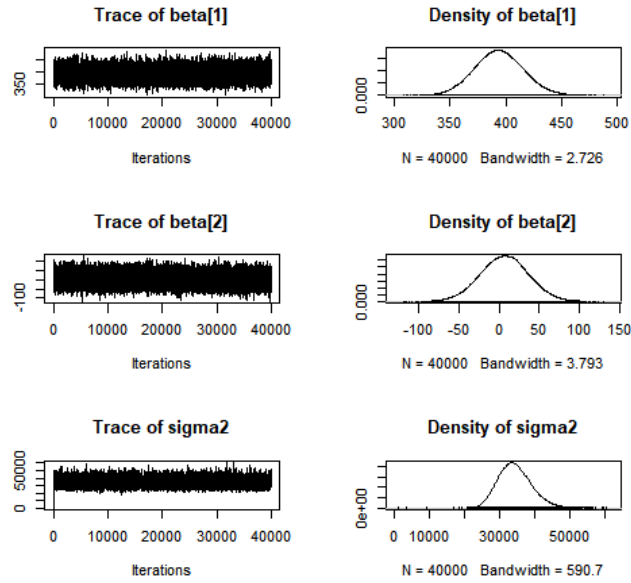
1 #####PREGUNTA 6
2
3 library(LearnBayes)
4
5 datos <- read.csv(file.choose())
6 attach(datos)
7
8 y <- datos$sRtimes
9 x <- datos$Mode
10
11 X <- cbind(1,x)
12 n <- length(y)
13
14 # Simulaciones
15 I <- 40000
16 beta <- matrix(0,nrow=I,2)
17 tau <- rep(0,I)
18
19 beta[1,] <- coef(lm(y~x))
20 tau[1] <- 0.001
21
22 for(i in 2:I)
23 {
24   # W_i
25   alpha.w <- 2
26

```

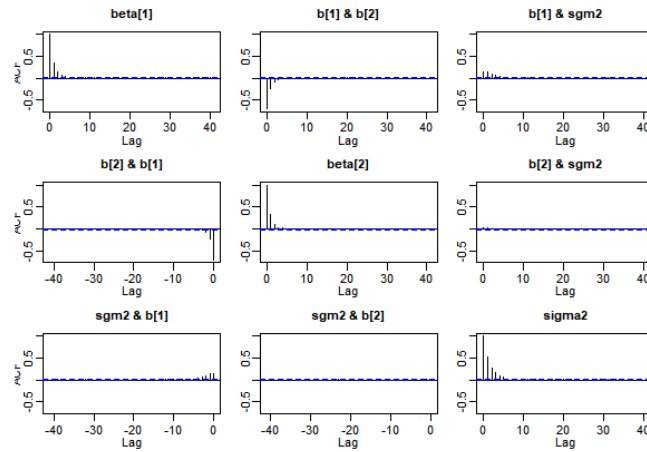
```

27 eta    <- c(y-X%%beta[i-1,])
28 beta.w <- 3/2 + 0.5*tau[i-1]*eta**2
29
30 W <- rgamma(n,alpha.w,beta.w)
31 #
32
33 # tau
34 tau[i] <- rgamma(1,n/2,0.5*sum(W*eta**2))
35 #
36 # beta
37 beta.hat <- coef(lm(y ~ x,weights=W,datos))
38 #beta.hat=solve(t(X)%%diag(z)%%X)%%t(X)%%diag(z)%%y
39 V      <- solve(t(X)%%diag(W)%%X)/tau[i]
40 beta[i,] <- rmnorm(1,beta.hat,V)
41 }
42
43
44 #Preg6.c
45
46 sim      <- cbind(beta=beta,sigma2=1/tau)
47 colnames(sim)[1:2] <- c("beta[1]","beta[2]")
48 sim      <- as.mcmc(sim)
49
50
51 summary(sim)
52 plot(sim)
53 acf(sim)
54
55 # Preg6.d
56 w1 = rgamma(I,3/2,3/2)
57
58 mu=numeric(I)
59 for (i in 1:I){
60 mu[i] = mean(X%%beta[i,])
61 }
62
63 y.pred=numeric(I)
64 y.pred <- rnorm(I,mu[i],sqrt(1/(w1*tau)))
65 hist(y.pred[1000:I])
66 plot(density(y.pred))
67 summary(y.pred)

```



Se determinaron los gráficos de distribución para cada parámetro. El gráfico de cadenas nos permite observar la estabilización de nuestros resultados. Se observa posteriormente que la correlación se vuelve nula entre cada una de ellas.



Se obtuvo el siguiente resumen estadístico

```

Iterations = 1:40000
Thinning interval = 1
Number of chains = 1
Sample size per chain = 40000

1. Empirical mean and standard deviation for each variable,
   plus standard error of the mean:

      Mean      SD Naïve SE Time-series SE
beta[1]  394.022  21.32   0.1066         0.1541
beta[2]    6.624  30.14   0.1507         0.2143
sigma2  34415.918 4717.06  23.5853         43.0560

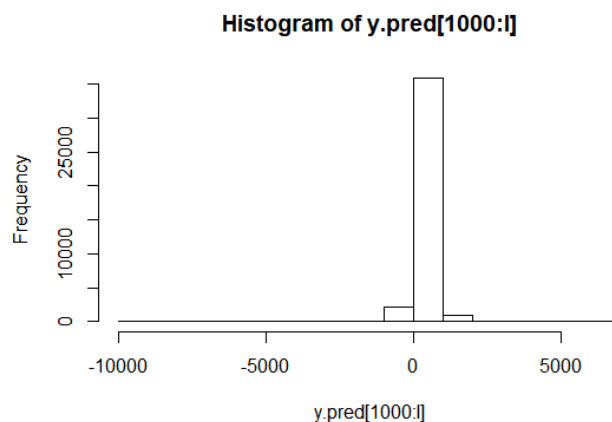
2. Quantiles for each variable:

      2.5%      25%      50%      75%     97.5%
beta[1]  352.75  379.61  393.731  408.21  436.9
beta[2]  -52.88  -13.54   6.734   26.75   65.6
sigma2  26205.13 31089.95 34076.382 37375.21 44610.6

```

Notamos que la varianza es un valor muy alto. Considerando el número de simulaciones hechas, iniciales, podemos decir que no existe una fluctuación errónea a causa del algoritmo.

Con respecto a la distribución predictiva se tiene lo siguiente:



Se tiene el siguiente resumen estadístico correspondiente

```

      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
-9484.0   268.7   408.2   408.1   547.3   6448.8

```