

# Inferencia Bayesiana

**Alumno:**

*Huertas Quispe, Anthony Enrique*

**Cod:** 20173728

**Semestre:** 2018-I

**Tema:** PC 3

PROF. VICTOR GIANCARLO SAL Y ROSAS



Pontificia Universidad Católica del Perú  
Escuela de Posgrado  
Maestría en Estadística

## Problema 1. (Distribución Rayleigh)

La distribución Rayleigh, denotada por  $X \sim \text{Rayleigh}(\sigma)$ , es usada para modelar el tiempo de vida de un sujeto donde la función de riesgo crece de manera lineal.

$$f(x) = \frac{x}{\sigma^2} \exp \left[ - \left( \frac{x^2}{2\sigma^2} \right) \right]$$

para  $x \in [0, \infty]$ .

Listing 1: Función de distribución Rayleigh

---

```
1 f <- function(x, sigma=2) { (x/sigma^2)*exp(-x^2/(2*sigma^2)) }
```

---

Asumiendo que  $\sigma = 2$ , responda las siguientes preguntas

- a) Use el algoritmo Metropolis - Hasting para generar observaciones de esta distribución. Use como función generadora

$$x^* \sim J(|x^{(s-1)}) = dchisq(df = x^{(s-1)})$$

Corrobore que puede recuperar la distribución usando la función **drayleigh** de la librería **VGAM**

*Solución.*

Listing 2: Metropolis-hasting / Función Generadora:  $\chi^2$

---

```
1 N <- 20000
2 x <- numeric(N)
3
4 # Valor inicial
5 x[1] <- 0.5
6
7 # Algoritmo Metropolis-Hasting
8 for(i in 2:N){
9   # Valor anterior
10  x.start<-x[i-1]
11
12  # Proponer (Funcion generadora : chi^2)
13  x.prop<-rchisq(1,df=x.start) # valor candidato
14
15  # Regla de aceptacion
16  u<-runif(1)
17  px.start_x.prop <- dchisq(x.start,df=x.start)
18  px.prop_x.start <- dchisq(x.prop,df=x.start)
19  r<-min(1,(f(x.prop)*px.start_x.prop)/(f(x.start)*px.prop_x.start))
20  if(u < r){x[i]<-x.prop}else{x[i]<-x.start} #acepta al candidato
21 }
22
23 # Valores simulados (Eliminando primeras 1000 observaciones)
24 x <- x[-c(1:1000)]
25 acf(x)
26 ts.plot(x,col=2,main=paste("Series de tiempo de x"))
27
28 # Histograma de distribucion
29 hist(x,prob=T,main=paste("Histograma of x"))
30 curve(drayleigh(x, scale=2), add=TRUE, col="blue")
```

---

□

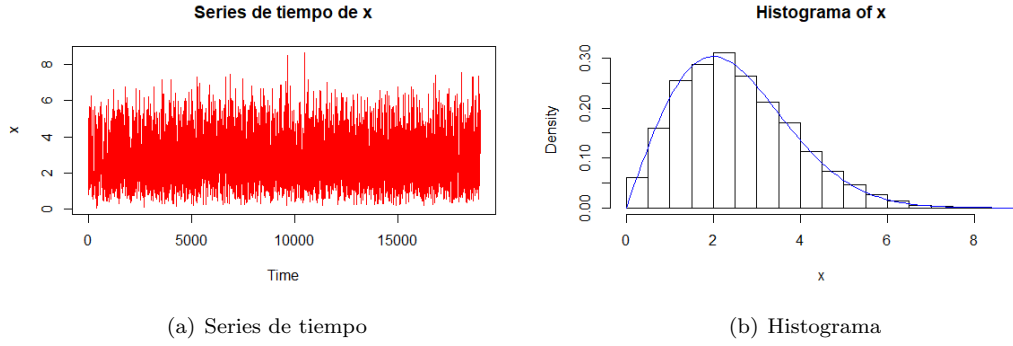


Figura 1: Simulación de una distribución Rayleigh por M-H usando como función generadora una  $\chi^2_{(k)}$ .

- b) La distribución normal truncada en  $[a, b]$ , es denotada por  $X \sim NT(\mu, \sigma^2, a, b)$  y tiene como función de densidad

$$f(x) = \frac{\phi\left(\frac{x-\mu}{\sigma}\right)}{\sigma \left[ \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right) \right]}$$

donde  $\phi$  y  $\Phi$  son la función de densidad y la función de distribución acumulada de la normal estándar, respectivamente. Se puede generar observaciones de esta distribución usando la función **rtnorm** de la librería **msm**. Repita la pregunta a) usando una normal truncada con función generadora.

*Solución.*

Listing 3: Metropolis-hasting / Función Generadora:  $TN$  (Normal Truncada).

---

```

1 library(msm)
2 N <- 20000
3 x <- numeric(N)
4
5 # Valor inicial
6 x[1] <- 0.5
7
8 # Algoritmo Metropolis-Hasting
9 for(i in 2:N){
10   # Valor anterior
11   x.start <- x[i-1]
12
13   # Proponer (Funcion generadora : TN)
14   x.prop <- rtnorm(1, mean=x.start, sd=1, lower=0, upper=Inf)
15
16   # Regla de aceptacion
17   u <- runif(1)
18   px.start_x.prop <- dtnorm(x.start, mean=x.prop, sd=1, lower=0, upper=Inf)
19   px.prop_x.start <- dtnorm(x.prop, mean=x.start, sd=1, lower=0, upper=Inf)
20   r <- min(1, (f(x.prop)*px.start_x.prop)/(f(x.start)*px.prop_x.start))
21   if(u < r){x[i] <- x.prop} else {x[i] <- x.start}
22 }
23
24 # Valores simulados
25 x <- x[-c(1:1000)]
26 acf(x)
27 ts.plot(x, col=2, main=paste("Series de tiempo de x"))
28
29 hist(x, prob=T, main=paste("Histograma of x"))
30 curve(drayleigh(x, scale=2), add=TRUE, col="blue")

```

---




Figura 2: Simulación de una distribución Rayleigh por M-H usando como función generadora una Normal Truncada.

□

c) Use una distribución Gamma como función generadora

$$J(y | x^{(s)}) = d\text{gamma}\left(x^*, \eta, \frac{\eta}{x^{(s-1)}}\right) = \frac{\left(\frac{\eta}{x^{(s-1)}}\right)^\eta}{\Gamma(\eta)} y^{\eta-1} \exp\left[-\frac{\eta}{x^{(s)}} y\right]$$

y reputa la pregunta a) considerando los valores  $\eta = 1$  y  $\eta = 2$ .

*Solución.*

Listing 4: Metropolis-hasting / Función Generadora: *Gamma*.

---

```

1 rayleigh_MH_gamma <- function(N=20000, sigma = 2, eta = 1){
2   x <- numeric(N)
3
4   # Valor inicial
5   x[1] <- -0.5
6   for(i in 2:N){
7     # Valor anterior
8     x.start <- x[i-1]
9
10    # Proponer
11    x.prop <- rgamma(1, shape = eta, rate = eta/x.start) # valor candidato
12
13    # Regla de aceptacion
14    u <- runif(1)
15    px.start_x.prop <- dgamma(x.start, shape = eta, rate = eta/x.start)
16    px.prop_x.start <- dgamma(x.prop, shape = eta, rate = eta/x.start)
17    r <- min(1, (f(x.prop)*px.start_x.prop)/(f(x.start)*px.prop_x.start))
18    if(u < r){x[i] <- x.prop} else {x[i] <- x.start} #acepta al candidato
19  }
20  x
21 }
```

---

Listing 5: Valores simulados con  $\eta = 1$ .

---

```

1 x <- rayleigh_MH_gamma(eta=1)[-c(1:1000)]
2 acf(x)
3 ts.plot(x, col=2, main=paste("Series de tiempo de x"))
4
5 hist(x, prob=T, main=paste("Histograma of x"))
6 curve(drayleigh(x, scale=2), add=TRUE, col="blue")
```

---

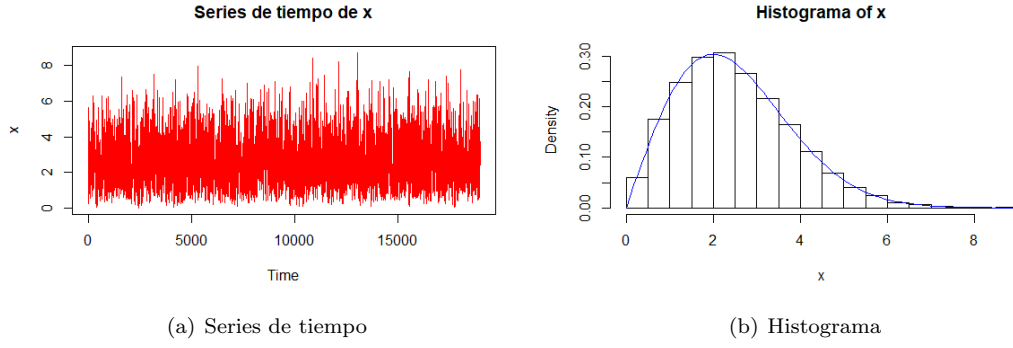


Figura 3: Simulación de una distribución Rayleigh por M-H usando como función generadora una Gamma con  $\eta = 1$ .

Listing 6: Valores simulados con  $\eta = 2$ .

---

```

1 x <- rayleigh.MH_gamma(eta=2)[-c(1:1000)]
2 acf(x)
3 ts.plot(x,col=2,main=paste("Series de tiempo de x"))
4
5 hist(x,prob=T,main=paste("Histograma of x"))
6 curve(drayleigh(x, scale=2), add=TRUE, col="blue")

```

---

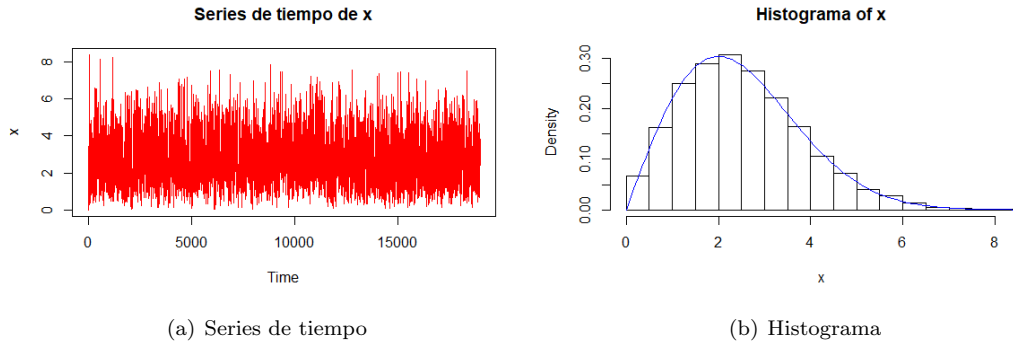


Figura 4: Simulación de una distribución Rayleigh por M-H usando como función generadora una Gamma con  $\eta = 2$ .

□

## Problema 2. (Regresión Logística Simple)

Consideremos implementar una regresión logística para estudiar los factores que podrían estar asociados con la probabilidad de caer en morosidad. En particular, deseamos estudiar la relación entre la **edad** del cliente y la probabilidad de caer en morosidad. La base de datos se puede leer de la siguiente forma

Listing 7: Importando datos

---

```

1 credito <- read.csv(file.choose())
2 credito <- credito[,1:10]
3 names(credito) <- c("id","censor","tiempo","bancarizado","sexo","soltero","edad","pcali",
4                   "tarjeta","linea")

```

---

a) Asumiendo que

$$\beta = (\beta_0, \beta_1) \sim N_2(\mu, \Sigma)$$

construya la distribución a posteriori de  $(\beta_0, \beta_1)$

*Solución.* Considerando la variable  $X : \text{Edad}$  y  $Y : \text{censor}$  entonces

$$Y \mid X = x \sim \text{Bernoulli}(\pi(x))$$

donde

$$\text{logit}(\pi(x)) = \beta_0 + \beta_1 x = \begin{pmatrix} 1 \\ x \end{pmatrix}^T \beta = \mathbf{x}^T \beta \Rightarrow \pi(x) = \frac{\exp(\mathbf{x}^T \beta)}{1 + \exp(\mathbf{x}^T \beta)}$$

La distribución a posteriori vendría representada, en parte, por

$$\begin{aligned}
 p(\beta \mid \mathbf{Y}) &\propto p(\mathbf{Y} \mid \beta) p(\beta) \\
 &\propto \left( \prod_{i=1}^n \left( \frac{\exp(\mathbf{x}_i^T \beta)}{1 + \exp(\mathbf{x}_i^T \beta)} \right)^{y_i} \left( \frac{1}{1 + \exp(\mathbf{x}_i^T \beta)} \right)^{1-y_i} \right) \times \exp \left( -\frac{1}{2} (\beta - \mu)^T \Sigma^{-1} (\beta - \mu) \right) \\
 &\propto \left( \prod_{i=1}^n \frac{\exp(\mathbf{x}_i^T \beta)^{y_i}}{1 + \exp(\mathbf{x}_i^T \beta)} \right) \times \exp \left( -\frac{1}{2} (\beta - \mu)^T \Sigma^{-1} (\beta - \mu) \right) \\
 &\propto \frac{\exp \left( \sum_{i=1}^n y_i \mathbf{x}_i^T \beta \right)}{\prod_{i=1}^n (1 + \exp(\mathbf{x}_i^T \beta))} \times \exp \left( -\frac{1}{2} (\beta - \mu)^T \Sigma^{-1} (\beta - \mu) \right) \\
 &\propto \frac{\exp \left( \sum_{i=1}^n y_i \mathbf{x}_i^T \beta - \frac{1}{2} (\beta - \mu)^T \Sigma^{-1} (\beta - \mu) \right)}{\prod_{i=1}^n (1 + \exp(\mathbf{x}_i^T \beta))}
 \end{aligned}$$

□

b) Implemente un algoritmo de Metropolis-Hasting para calcular la distribución a posteriori de  $(\beta_0, \beta_1)$  asumiendo una función generadora normal bivariada

$$\beta^* \sim N_2 \left( \beta^{(t-1)}, \tau \Sigma \right)$$

donde  $\Sigma$  es la matriz de covarianza del modelo de regresión frecuentista y  $\tau$  es un parámetro de precisión.

*Solución.*

Listing 8: Metropolis-Hasting

```

1 # Modelo frecuentista
2 model.logit.freq <- glm(censor ~ edad, family="binomial",credito)
3
4 # Algoritmo Metropolis-Hasting
5 Logistic.M <- function(tau = 2,
6                         y = credito$censor,
7                         X = model.matrix(~ edad,credito),
8                         Delta = diag(dim(X)[2]),
9                         beta0 = rep(0,dim(X)[2]),
10                        Sbeta0 = diag(dim(X)[2]),
11                        beta = matrix(rep(0,dim(X)[2]),nrow=1),
12                        I=20000){
13   BETA <- NULL
14
15   for(i in 1:I){
16     # Proponer
17     beta.start <- rmvnorm(1,beta,tau*Delta)
18
19     # Asignaciones previas
20     pi.start <- exp(X%*%(beta.start))*(1 + exp(X%*%(beta.start)))^(-1)
21     pi.beta <- exp(X%*%(beta))*(1 + exp(X%*%(beta)))^(-1)
22
23     log.r <- sum(dbinom(y,1,pi.start,log=T)) - sum(dbinom(y,1,pi.beta,log=T))
24             + dmvnorm(beta.start,beta0,Sbeta0,log=TRUE)
25             - dmvnorm(beta,beta0,Sbeta0,log=TRUE)
26
27     # Aceptacion
28     if(log.r > log(runif(1))) beta <- beta.start
29     BETA <- rbind(BETA,beta)
30     colnames(BETA) <- c("beta0","beta1")
31   }
32
33   # Estimaciones
34   BETA
35 }
36
37 ##### Evaluado con Matriz de Varianza-Covarianza del modelo frecuentista
38 # tanto para la funcion generadora como para la distribucion priori
39 ##### Se esta tomando a 1 como la precision.
40 logistic.1 <- Logistic.M(tau = 1,
41                          Delta = summary(model.logit.freq)$cov.unscaled,
42                          Sbeta0 = summary(model.logit.freq)$cov.unscaled, I = 20000)
43
44 # Graficas de distribucion, autocorrelacion
45 plot(as.mcmc(logistic.1[-c(1:1000),]))
46 acf(as.mcmc(logistic.1[-c(1:1000),]))
47
48 # Resumen de datos
49 summary(as.mcmc(logistic.1[-c(1:1000),]))

```

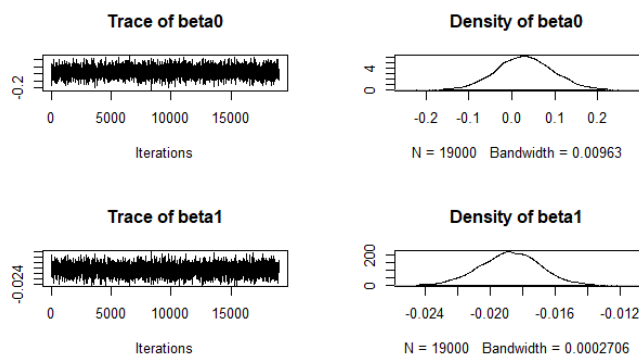


Figura 5: Gráficas de densidades

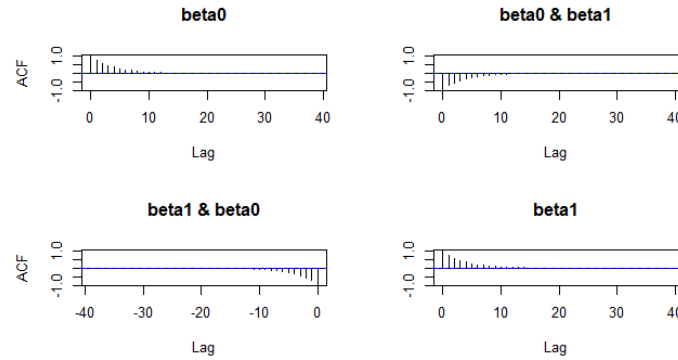


Figura 6: Gráficas de Autocorrelaciones

Se han determinado las densidades para  $\beta_0$  y  $\beta_1$ , habiéndose eliminado los 1000 primeros valores generados con el fin de una mejor representación. Como notamos las autocorrelaciones disminuyen conforme aumenta el número de iteraciones lo cual es ideal para la estimación de los parámetros.

```
Iterations = 1:19000
Thinning interval = 1
Number of chains = 1
Sample size per chain = 19000

1. Empirical mean and standard deviation for each variable,
   plus standard error of the mean:

      Mean      SD Naive SE Time-series SE
beta0  0.02963 0.065172 4.728e-04      0.001298
beta1 -0.01878 0.001832 1.329e-05      0.000036

2. Quantiles for each variable:

      2.5%      25%      50%      75%      97.5%
beta0 -0.09695 -0.01491  0.02902  0.07325  0.16027
beta1 -0.02243 -0.01999 -0.01876 -0.01753 -0.01521
```

Figura 7: Estimación de  $\beta$ .

Se presenta un resumen de los obtenido, en donde estimaciones puntuales, en particular la media, nos dan  $\beta_0 = 0.02963$  y  $\beta_1 = -0.01878$ .

□

c) Calcula la probabilidad de caer en morosidad a posteriori. Es decir

$$\pi(x) = \frac{\exp(\beta_0 + \beta_1 x)}{1 + \exp(\beta_0 + \beta_1 x)}$$

y proponga un ancho de banda para esta probabilidad.

*Solución.* El modelo tiene una forma en la cual podemos determinar la media del logaritmo de odds como

$$\log\left(\frac{\pi(x)}{1 - \pi(x)}\right) = 0.02963 - 0.01878 \times \bar{x}$$

con  $\bar{x}$  el promedio de las edades. Por lo que la estimación para la probabilidad de caer en morosidad podemos calcularla como

$$\pi(x) = \frac{\exp(0.02963 - 0.01878 \times \bar{x})}{1 + \exp(0.02963 - 0.01878 \times \bar{x})} \quad (1)$$



Ahora, para determinar el ancho de banda primero determinaremos el intervalo de confianza, al  $(1-\alpha \%)$  para el logaritmo de odds, siendo este

$$\begin{aligned}
 IC_{\logit(\pi(x))} &= \hat{\beta}_0 + \hat{\beta}_1 x \pm Z_{1-\alpha/2} \times \sqrt{Var(\hat{\beta}_0 + \hat{\beta}_1 x)} \\
 &= (1, x)^T (\beta_0, \beta_1) + \pm Z_{1-\alpha/2} \sqrt{(1, x)^T Var(\hat{\beta}_0, \hat{\beta}_1) (1, x)} \\
 \Rightarrow IC_{\pi(x)} &= \frac{\exp \left( (1, x)^T (\beta_0, \beta_1) + \pm Z_{1-\alpha/2} \sqrt{(1, x)^T Var(\hat{\beta}_0, \hat{\beta}_1) (1, x)} \right)}{1 + \exp \left( (1, x)^T (\beta_0, \beta_1) + \pm Z_{1-\alpha/2} \sqrt{(1, x)^T Var(\hat{\beta}_0, \hat{\beta}_1) (1, x)} \right)}
 \end{aligned}$$

Listing 9: Metropolis-Hasting

---

```

1 library(arm)
2 # beta0 y beta1 valores medios
3 coef = summary(as.mcmc(logistic.1[-c(1:1000)],)))[1]$'statistics'[,1]
4
5 # Funcion de prediccion para x
6 predict.x <- function(x=0, Delta = summary(model.logit.freq)$cov.unscaled, confianza = 0.95)
7 {
8   tmp <- t(matrix(c(1,x))) %*% Delta %*% matrix(c(1,x))
9   tmp <- qnorm(1-(1-confianza)/2)*sqrt(tmp)
10  pi_x <- invlogit(t(matrix(c(1,x)))%*%coef)
11  pi_x.minus <- invlogit(t(matrix(c(1,x)))%*%coef - tmp)
12  pi_x.plus <- invlogit(t(matrix(c(1,x)))%*%coef + tmp)
13  return(c(pi_x.minus,pi_x,pi_x.plus))
14 }
15
16 # Graficando ancho de banda "Edad" vs "Probabilidad de caer en morosidad"
17 x_raw <- seq(19,72,0.1)
18 N_raw <- dim(data.frame(x_raw))[1]
19 pi_x_raw <- rep(0,N_raw)
20 ht <- seq(19,72,length.out = dim(X)[1])
21 p_h <- matrix(0,nrow=dim(X)[1],ncol=3)
22
23 for (i in 1:N_raw) { pi_x_raw[i] = predict.x(x=x_raw[i])[2]}
24 for (i in 1:dim(X)[1]){ p_h[i,] <- predict.x(x = ht[i])}
25
26 plot(x = x_raw, y = pi_x_raw ,type = 'l')
27 polygon(c(ht,rev(ht)),c(p_h[,1],rev(p_h[,3])),col = rgb(1, 0, 0,0.5), border = NA)
28 lines(x= ht, y = p_h[,3], lty = 'dashed', col = 'red')
29 lines(x= ht, y = p_h[,2])
30 lines(x= ht, y = p_h[,1], lty = 'dashed', col = 'red')

```

---




Figura 8: Banda de confianza al 95 %.

Calculamos la ecuación determinada en (1),

Listing 10: Probabilidad de caer en morosidad

---

```
1 predict.x(x=mean(X[,2]))
```

---

Como resultado se obtiene que la probabilidad de caer en morosidad es de 0.3475226, con un intervalo de confianza de

[0.3346837, 0.3605872]

□

- d) Calcula la probabilidad de caer en morosidad para una nueva persona de 30 años de edad y su intervalo de credibilidad asociado

*Solución.* Usando la función de predicción determinada en el item c),

Listing 11: Probabilidad de caer en morosidad para x=30

---

```
1 predict.x(x=30)
```

---

Como resultado se obtiene una probabilidad de 0.3696386, con un intervalo de confianza al 95 %

[0.3560335, 0.3834541]

□

## Problema 4. (Modelos Lineal Mixto)

Considere la base de datos **biomechanish.csv**. Esta base se obtuvo al realizar pruebas a 10 personas un número determinado de veces. Se desea estimar el efecto de la variable motion (X) en el delay de la persona i-ésima para intento j-ésimo.

Es decir,

$$Y_{ij} = X_{ij}^T \beta + b_i + \varepsilon_{ij}$$

donde  $\varepsilon_{ij} \sim N(0, \sigma^2)$  y  $b_i \sim N(0, \sigma_b^2)$ .

a) Construya un algoritmo de Gibbs para estimar la distribución a posteriori de  $\beta$ ,  $\sigma^2$  y  $\sigma_b^2$ .

Tenemos lo siguiente:

$$Y_{ij} \sim N(X_{ij}^T \beta, \sigma^2 + \sigma_b^2) \quad ; \quad Y_{ij} \mid b_i \sim N(X_{ij}^T \beta + b_i, \sigma^2)$$

Además,

$$\begin{aligned} \text{Cov}(Y_{ij}, Y_{ik}) &= \sigma_b^2 \\ \text{Cov}(Y_{ij}, Y_{i'j'}) &= 0 \text{ con } j \neq j' \end{aligned}$$

Se determinará la respectiva proporción de la distribución a posteriori de los parámetros desconocidos, (reemplazando inicialmente  $\phi = 1/\sigma^2$  y  $\phi_b = 1/\sigma_b^2$  como las precisiones respectivas).

$$\begin{aligned} p(\beta, \phi, \phi_b, \mathbf{b} \mid \mathbf{Y}, \mathbf{X}) &\propto p(\mathbf{Y} \mid \mathbf{X}, \beta, \phi, \phi_b, \mathbf{b}) p(\mathbf{b} \mid \phi_b) \\ &\propto \prod_i \prod_j p(Y_{ij} \mid X_{ij}, \beta, \phi, b_i) \prod_i p(b_i \mid \phi_b) \end{aligned}$$

Esto continua de la siguiente forma

$$\begin{aligned} &\propto \left[ \prod_i \prod_j \phi^{1/2} \exp \left\{ -\frac{1}{2} \phi (Y_{ij} - X_{ij}^T \beta - b_i)^2 \right\} \right] \times \prod_i \phi_b^{1/2} \exp \left\{ -\frac{1}{2} \phi_b b_i^2 \right\} \\ &\propto \phi^{n/2} \exp \left\{ -\frac{1}{2} \phi \sum_{i,j} (Y_{ij} - X_{ij}^T \beta - b_i)^2 \right\} \times \phi_b^{m/2} \exp \left( -\frac{1}{2} \phi_b \sum_i b_i^2 \right) \end{aligned}$$

donde  $n$  es la cantidad total de observaciones y  $m$  es la cantidad de individuos.

Elaborando las distribuciones condicionales

$$\begin{aligned} b_i \mid \beta_0, \beta_1, \phi, \phi_b &\sim N \left( \frac{\phi \sum_j (Y_{ij} - X_{ij}^T \beta)}{n_i \phi + \phi_b}, (n_i \phi + \phi_b)^{-1} \right) \\ \beta \mid \phi, \phi_b, \mathbf{b} &\sim N_2 \left( (X X^T)^{-1} X (Y - \mathbf{b}), \frac{(X X^T)^{-1}}{\phi} \right) \\ \phi \mid \beta_0, \beta_1, \phi_b &\sim \text{Gamma} \left( \frac{n}{2} + 1, \frac{1}{2} \sum_{i,j} (Y_{ij} - X_{ij}^T \beta - b_i)^2 \right) \\ \phi_b \mid \beta_0, \beta_1, \phi &\sim \text{Gamma} \left( \frac{m}{2} + 1, \frac{1}{2} \sum_i b_i^2 \right) \end{aligned}$$

Listing 12: Probabilidad de caer en morosidad

---

```

1 library(MCMCpack)
2 library(data.table)
3 library(LearnBayes)
4
5 bio <- read.csv(file.choose())
6 bio <- data.frame(bio)
7 attach(bio)
8
9 bio <- bio[order(Subject),]
10 m <- 10
11 ni <- numeric(m)
12 for (i in 1:m){
13   ni[i] <- dim(bio[c(bio$Subject==i),])[1]
14 }
15
16 database<-list()
17 a=c(0,ni)
18 for (i in 1:10){
19   database[[i]] <- bio[(1+sum(a[1:i])):sum(a[1:i+1]),]
20 }
21
22 y <- bio$Delayms
23 x <- bio$Motion
24 X <- cbind(1,x)
25 n <- length(y)
26
27 # Simulaciones
28 I <- 20000
29 beta <- matrix(0,nrow = I,2)
30 bi <- matrix(0,nrow = I,m)
31 sigma2 <- rep(0,I)
32 sigma2.b <- rep(0,I)
33 phi <- rep(0,I)
34 phi.b <- rep(0,I)
35
36 beta[1,] <- coef(lm(y~x))
37 sigma2[1] <- 1
38 sigma2.b[1] <- 1
39 phi[1]<-1/sigma2[1]
40 phi.b[1] <- 1/sigma2.b[1]
41
42 for (h in 2:I) {
43   #beta
44   y_hat <- c()
45   for (i in 1:m){
46     y_hat <- c(y_hat,rep(bi[h-1,i],ni[i]))
47   }
48
49   mu.beta <- solve(t(X)%*%X)%*%t(X)%*(matrix(y-y_hat))
50   V.beta <- solve(t(X)%*%X)/phi[h-1]
51   beta[h,] <- rmnorm(1,mu.beta,V.beta)
52
53   #bi
54   for (i in 1:m) {
55     Xi <- cbind(1,database[[i]]$Motion)
56     Yi <- database[[i]]$Delayms
57     mu <- phi[h-1]*sum(Yi-Xi)%*%beta[h,]/(ni[i]*phi[h-1]+phi.b[h-1])
58     var_bi <- 1/(ni[i]*phi[h-1]+phi.b[h-1])
59     bi[h,i] <- rnorm(1,mu,sqrt(var_bi))
60   }
61
62   #phib
63   phib.alpha <- m/2+1
64   phib.beta <- (1/2)*sum((bi[h])^2)
65   phi.b[h] <- rgamma(1,shape = phib.alpha,rate = phib.beta)
66   sigma2.b[h] <- 1/phi.b[h]
67
68   #phi
69   y_hat <- c()
70   for (i in 1:m){
71     y_hat <- c(y_hat,rep(bi[h,i],ni[i]))
72   }

```

```

73     phi.alpha <- n/2 + 1
74     phi.beta <- (1/2)*sum((y-y_hat-X%*%beta[h,])^2)
75     phi[h] <- rgamma(1,shape = phi.alpha,rate = phi.beta)
76     sigma2[h] <- 1/phi[h]
77 }
78
79 colnames(beta)<-c("beta0","beta1")
80 colnames(sigma2)<-c("sigma2")
81 colnames(sigma2.b)<-c("sigma2.b")
82
83 plot(as.mcmc(beta))
84 plot(as.mcmc(sigma2))
85 plot(as.mcmc(c(sigma2.b)))
86
87 summary(as.mcmc(beta))
88 summary(as.mcmc(sigma2))
89 summary(as.mcmc(sigma2.b))
90

```

---

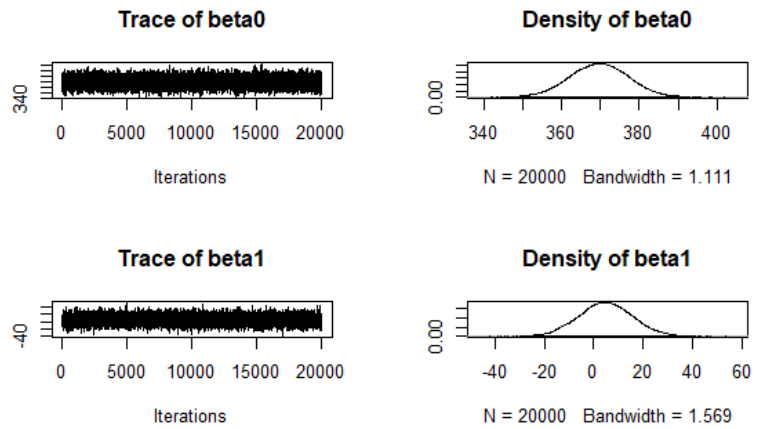

(a) Distribución a posteriori de  $\beta$ (b) Distribución a posteriori de  $\sigma^2$ 

Figura 9: Distribución a posteriori de los parámetros desconocidos.

A continuación se presentan resumen de datos

	Media	SD
$\beta_0$	369.626	7.593
$\beta_1$	4.788	10.810
$\sigma^2$	6701.390	633.134
$\sigma_b^2$	0.0001635	0.0154166